

Análisis de Productividad en Manufactura

En el entorno de la manufactura, la optimización de la productividad y el rendimiento laboral son aspectos fundamentales para la eficiencia y competitividad de las empresas. En este contexto, el desarrollo de herramientas de análisis de datos se ha vuelto crucial para entender y mejorar los procesos de producción y el desempeño de los empleados en las plantas industriales.


Este proyecto se enfoca en la creación de un producto de análisis de datos sobre productividad en manufactura, dirigido a satisfacer las necesidades específicas de los usuarios finales en dos áreas clave: el área de producción y el área de recursos humanos. A través de este producto, se busca proporcionar insights valiosos que permitan a los usuarios tomar decisiones informadas y estratégicas para mejorar la eficiencia y el desempeño en la planta.

A partir de lo anterior, se desean estudiar las siguiente preguntas de negocio:

¿Cuál es el efecto de los incentivos financieros en la productividad de los empleados del departamento de Sweing?

Entender el impacto de los incentivos financieros en la productividad de los empleados del departamento de Sweing es esencial para maximizar la eficiencia y el rendimiento en el proceso de fabricación. Al conocer cómo los incentivos afectan el desempeño de los trabajadores en este departamento específico (finishing no recibe incentivos), la empresa puede tomar decisiones más informadas sobre cómo estructurar y administrar los programas de incentivos para motivar al equipo y mejorar los resultados de producción.

Resultados:



OLS Regression Results						
Dep. Variable:	actual_productivity	R-squared:	0.647			
Model:	OLS	Adj. R-squared:	0.646			
Method:	Least Squares	F-statistic:	1261.			
Date:	Tue, 12 Mar 2024	Prob (F-statistic):	8.54e-158			
Time:	20:42:57	Log-Likelihood:	668.66			
No. Observations:	691	AIC:	-1333.			
Df Residuals:	689	BIC:	-1324.			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]
Intercept	0.5214	0.007	78.429	0.000	0.508	0.534
incentive	0.0045	0.000	35.510	0.000	0.004	0.005
=====						
Omnibus:	79.314	Durbin-Watson:	1.401			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	161.577			
Skew:	-0.677	Prob(JB):	8.20e-36			
Kurtosis:	4.944	Cond. No.	99.4			

Se grafica la variable `actual_productivity` vs `incentive_category`, esta última es una variación de la variable 'incentive' que toma los valores más recurrentes de incentivos que van desde 0 hasta 120 y los divide entre 10 para que cualquier valor entre 0 y 9 se redondeará a 0, cualquier valor entre 10 y 19 se redondeará a 1, y así sucesivamente. La gráfica muestra una tendencia ascendente en la mediana de la productividad a medida que aumenta el número de incentivos.


Por lo anterior, se procede a realizar una regresión lineal la cual presenta un R-cuadrado ajustado es 0.646, lo que significa que aproximadamente el 64.6% de la variabilidad en la productividad actual puede ser explicada por el modelo. Por otro lado, el p-value presenta un valor muy pequeño lo que

sugiere que el modelo en su conjunto es estadísticamente significativo. Asimismo se observa que, Para cada unidad de aumento en 'incentive', se espera un aumento de 0.0045 en 'actual_productivity'


Conclusión: Los incentivos financieros tienen un impacto positivo en la productividad de los empleados del departamento de Sweing. Por lo tanto, la empresa podría considerar la implementación de programas de incentivos adecuados como una estrategia para mejorar el rendimiento y la eficiencia en el proceso de fabricación

¿Cómo varía la productividad entre diferentes equipos o departamentos?

Evaluar la diferencia de productividad entre los departamentos es crucial porque proporciona información clave sobre la eficiencia y el desempeño de cada área dentro de la organización. Identificar las disparidades en la productividad entre departamentos puede ayudar a detectar posibles problemas operativos, ineficiencias en los procesos de trabajo o áreas donde se necesitan mejoras en la gestión de recursos.



Resultados: Se grafica la productividad (Objetivo-Real) vs Departamento-Número de equipo. La primera es el promedio de la diferencia entre la variable target_productivity y actual_productivity, esto para cada equipo según al departamento que pertenece. Se evidencia que el desempeño de los equipos del departamento de sweing tienen menos equipos que en promedio no han cumplido con sus objetivos , exactamente 4. Mientras que el departamento de finishing tiene dos equipos adicionales que no han cumplido con sus targets, exactamente 6.



A pesar de todo lo anterior, se deben considerar que los valores extremos pueden distorsionar significativamente el promedio y que debido a que estos datos no presentan una distribución normal, en esta distribución asimétrica o sesgada es bueno incluir la medida de la mediana debido a que esta es menos atípica a los valores atípicos.


Al graficar la diferencia entre la productividad objetivo y la actual y al calcular su mediana, se destaca un patrón interesante en el departamento de Sweing. La mayoría de los equipos en este departamento parecen cumplir usualmente con lo requerido en su target, reflejando un comportamiento consistente con las expectativas de productividad. Sin embargo, es importante señalar que el equipo 1 difiere de este comportamiento. Este hallazgo también

muestra como el departamento de finishing a pesar de contar con 4 equipos que usualmente cumplen con sus metas estando incluso 0,15 por encima del target, hay 8 equipos restantes que no alcanzan con lo requerido.

Conclusión: La productividad entre los dos equipos sugiere que el departamento de Sweing tiene un mejor desempeño general en términos de productividad en comparación con Finishing. Lo anterior, implica que hay que hacer una revisión en las metas, mirar si estas son alcanzables y realistas, asimismo, Analizar en detalle los procesos y prácticas utilizadas en el departamento de Sweing que han contribuido a su alto rendimiento. Estas mejores prácticas pueden ser implementadas en el departamento de Finishing para mejorar su productividad.

¿Qué impacto tienen las interrupciones en la producción en la productividad de los empleados?

Las interrupciones pueden provocar retrasos en la ejecución de tareas, interrupción de flujos de trabajo, pérdida de tiempo y recursos lo que puede conducir a una disminución en la producción y mayores costos operativos. Por lo tanto, es fundamental para las empresas identificar las causas de las interrupciones en la producción y desarrollar estrategias efectivas para mitigar su impacto, asegurando así un entorno de trabajo más eficiente y productivo.



Resultados: Se grafica target_productivity vs prod_detenida. Paralelamente actual_productivity vs prod_detenida. Prod detenida toma valor de false cuando la producción NO está detenida, mientras que toma valor de True cuando SÍ está detenida. Cabe aclarar que las veces que se detuvo la producción es significativamente menor que las veces que no se ha detenido, sin embargo, se logra evidenciar que cuando se detiene la producción, la productividad real disminuye en casi un 0,1.

Conclusión: Dado que las interrupciones en la producción pueden tener un impacto en la productividad de los empleados, se recomienda que las empresas continúen priorizando la reducción de las interrupciones en sus operaciones.

¿El tiempo asignado en una tarea influye en la productividad del departamento de finishing?

Evaluar si el tiempo asignado a una tarea influye en la productividad del departamento de finishing es importante porque puede proporcionar información crucial sobre la eficiencia de los procesos de trabajo y la gestión del tiempo en ese departamento específico.

Resultados: El modelo de regresión lineal que has ajustado muestra que el coeficiente de determinación R cuadrado ajustado es 0.042, lo que indica que aproximadamente el 4.2% de la variabilidad en la variable de respuesta (actual_productivity) puede explicarse por la variable predictora (smv). Esto sugiere que la relación entre la productividad actual y el smv es débil. El coeficiente para la variable smv es 0.0680, lo que significa que, en promedio, por cada unidad de aumento en el smv, se espera un aumento de 0.0680 en la actual_productivity. Este coeficiente es estadísticamente significativo, ya que el valor p asociado es menor que el nivel de significancia típico de 0.05.

OLS Regression Results						
Dep. Variable:	actual_productivity		R-squared:	0.042		
Model:	OLS		Adj. R-squared:	0.040		
Method:	Least Squares		F-statistic:	22.11		
Date:	Tue, 12 Mar 2024		Prob (F-statistic):	3.32e-06		
Time:	22:33:48		Log-Likelihood:	115.35		
No. Observations:	506		AIC:	-226.7		
Df Residuals:	504		BIC:	-218.2		
Df Model:	1					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	0.4887	0.057	8.596	0.000	0.377	0.600
smv	0.0680	0.014	4.703	0.000	0.040	0.096
Omnibus:	50.316		Durbin-Watson:	1.229		
Prob(Omnibus):	0.000		Jarque-Bera (JB):	63.630		
Skew:	-0.867		Prob(JB):	1.52e-14		
Kurtosis:	3.117		Cond. No.	27.7		

Conclusión: Aunque el modelo muestra una relación estadísticamente significativa entre el tiempo asignado a una tarea (smv) y la productividad del departamento de finishing, la influencia del smv en la productividad es débil, explicando solo aproximadamente el 4.2% de la variabilidad observada en la productividad. Esto sugiere que otros factores no incluidos en el modelo pueden estar desempeñando un papel importante en la productividad de este departamento.

Limpieza de datos

Durante el proceso de limpieza de datos, se realizó una inspección inicial de los mismos, lo que reveló la presencia de valores de "actual_productivity" que estaban fuera del rango permitido [0:1]. Estos datos se eliminaron para garantizar la integridad del conjunto de datos.

Además, al examinar los departamentos incluidos en el modelo, se identificó la presencia de dos categorías denominadas "finishing". Para evitar redundancias, se decidió combinar estas dos categorías en una sola.

Una revisión más detallada de la variable "WIP" reveló la existencia de numerosos valores nulos, que al ser contrastados con la naturaleza del departamento, se determinó que pertenecían al departamento de "finishing". Se supone que esto se debe a la inexistencia de trabajo en proceso en dicho departamento, por lo que se procedió a reemplazar los valores nulos por 0.

Finalmente, se detectaron valores atípicos en algunas variables, como "incentive". Estos valores fueron considerados como anomalías y fueron eliminados del conjunto de datos para evitar que afectaran negativamente el análisis.

Modelo de predicción de Productividad:

Este modelo de predicción se inició con las variables numéricas mediante una regresión lineal, un método estadístico que busca modelar la relación entre una variable dependiente y una o más variables independientes (Rugeles Ospina, Nicolás). Sin embargo, se encontró que una red neuronal ofrece una precisión predictiva superior a la regresión lineal. Las redes neuronales son modelos computacionales inspirados en el funcionamiento del cerebro humano, compuestos por unidades básicas llamadas neuronas organizadas en capas interconectadas (Herbert Jones). Estas redes tienen la capacidad de capturar relaciones complejas en los datos, lo que las hace más adecuadas para ciertos problemas de predicción.

Luego, se incorporaron las variables categóricas utilizando la técnica de variables dummy, que consiste en convertir variables categóricas en variables binarias, lo que permite su inclusión en modelos de regresión. Sin embargo, el error cuadrático medio (MSE) no alcanzó el nivel deseado. Gracias al análisis se determinó que era más efectivo predecir la productividad por departamento, departamentos de "sewing" y "finishing".

En el caso del departamento de "sewing", se identificaron variables significativas como el incentivo, el SVM (Valor de minutos estándar) y el WIP (Trabajo en progreso), aunque estas últimas no tuvieron una influencia significativa en la predicción. Se concluyó que el modelo predictivo más efectivo se basa en la variable de incentivo, siendo la red neuronal la más adecuada para este propósito. El error cuadrático medio (MSE) y el coeficiente de determinación (R^2) para este modelo fueron respectivamente: Mean Squared Error: 0.007168977699018981, R^2 : 0.6089119195328764.

Por otro lado, en el departamento de "finishing", las variables predictivas fueron menos significativas y se observó una correlación baja con el nivel de productividad, posiblemente debido a la naturaleza de finalización de este proceso. En este caso, la variable SMV (Valor de minutos estándar) resultó ser la más relevante y se usó para el modelo predictivo.

Bibliografía:

Herbert Jones. *Las redes neuronales: Una guía esencial para principiantes de las redes neuronales artificiales y su papel en el aprendizaje automático y la inteligencia artificial*. Steven Turner.

Rugeles Ospina, Nicolás. "Algoritmos de Boosting para modelos de clasificación y regresión lineal." Universidad de los Andes, 2022.